


Tecnológico de Monterrey

# Proyecto MiBici

# Monitoreo de drift y comparación A/B

Operaciones de aprendizaje automático (MLOps)
TC5061 | Entregable 8 | Equipo 45

Efren Pazzi Manzano
A01326815

Franco Francisco Peña Colorado
A01793289

Leonardo Peraza Alavez
A01840326

Aldo Isai Pérez Hernández
A01797871

Profesor: Iván Reyes Amezcua

14 de noviembre de 2026

Repositorio del equipo en GitHub

# 1. Datos y monitoreo con Evidently

Se evalúa P1: demanda de salidas por estación para la siguiente hora. El periodo actual simula producción con datos abiertos posteriores; no corresponde a tráfico real de la API. La referencia coincide con el entrenamiento de A y septiembre queda fuera del ajuste de ambas versiones.

| Conjunto P1 | Periodo de 2026 | Filas | Estaciones |
|---|---|---|---|
| Referencia / A | 8 ene. - 30 jun. | 1,552,105 | 413 |
| Intermedio | 1 jul. - 31 ago. | 665,747 | 470 |
| Actual / evaluación | 1 - 30 sep. | 338,690 | 471 |

Los primeros siete días de enero se excluyen por los rezagos de 168 horas. B incorpora enero-agosto (2,217,852 filas). Las particiones respetan el horizonte de una hora y el calendario local de Ciudad de México. Las variables usan historia disponible en cada fecha.

Evidently 0.7.23 compara nueve variables: cinco numéricas y cuatro categóricas. Utiliza Wasserstein normalizada y Jensen-Shannon, respectivamente, con umbral 0.10. Hay drift del conjunto cuando al menos 50 % de las variables supera su umbral. Son distancias, no valores p. Se conserva la configuración del equipo (Evidently AI, s. f.).

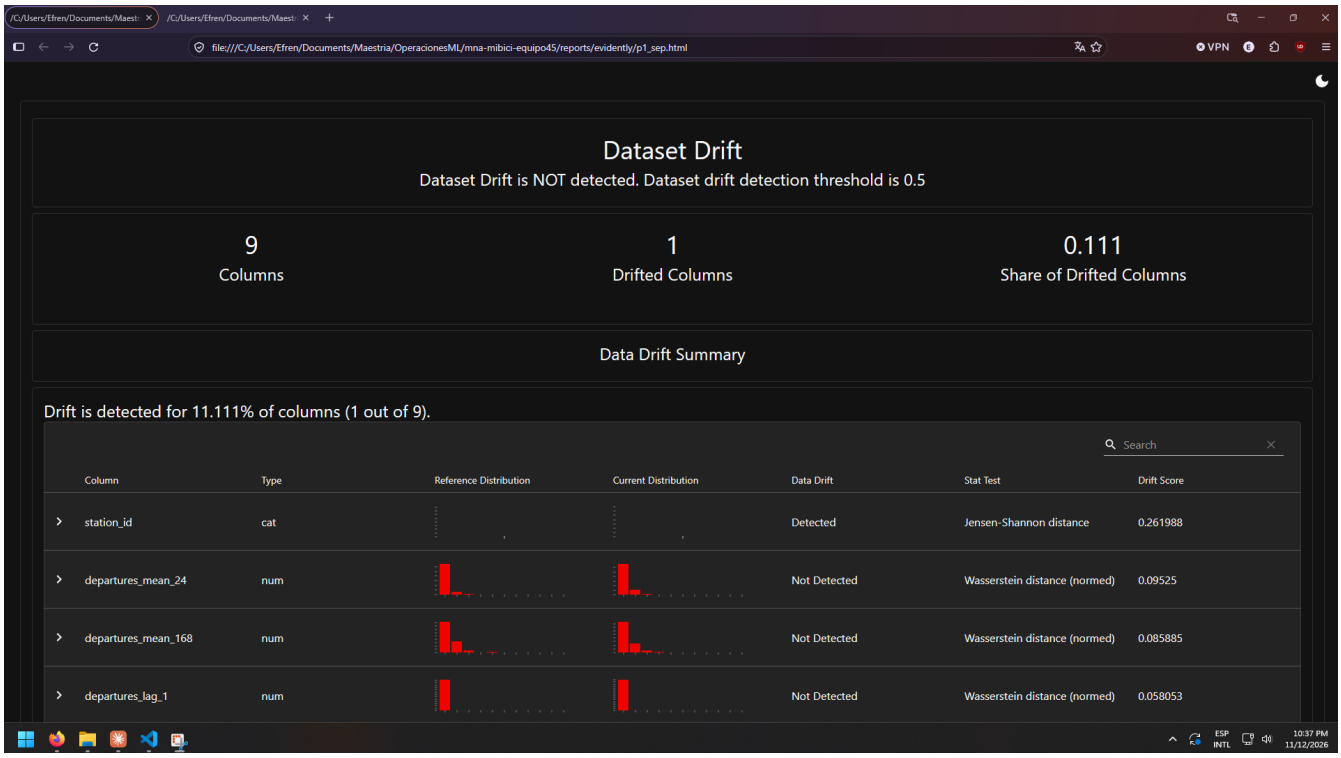



**Figura 1.** Reporte real de Evidently para P1: una de nueve variables presenta drift (11.1 %); no se activa la alerta global. Las distribuciones se incluyen en la captura. Fuente: evidencia del PR #20 y HTML p1_sep.html.

El modelo recibe diez predictores. El monitoreo excluye **month** porque los periodos cubren meses distintos por definición; esta exclusión evita una alerta calendárica trivial y limita el alcance del resumen. El timestamp se conserva para la auditoría, sin contarlo como predictor monitorizado.

# 2. Interpretación y calidad de datos

| Variable P1 | Distancia en septiembre | Drift (> 0.10) |
|---|---|---|
| departures_lag_1 | 0.058053 | No |
| departures_lag_24 | 0.047732 | No |
| departures_lag_168 | 0.025917 | No |
| departures_mean_24 | 0.095250 | No |
| departures_mean_168 | 0.085885 | No |
| station_id | 0.261988 | Sí |
| hour | 0.000729 | No |
| weekday | 0.039510 | No |
| is_weekend | 0.016835 | No |

**station_id** cambia de forma persistente: 0.228546 en julio-agosto y 0.261988 en septiembre. Hay 58 estaciones no observadas por A, que aportan 41,330 filas (12.20 % de septiembre). Esto exige vigilar cobertura y errores por estación; la ausencia de una alerta global no garantiza un desempeño estable.

En julio-agosto también supera el umbral **departures_mean_168** (0.105192): cambia la demanda media semanal reciente. En septiembre vuelve a 0.085885; la media de 24 horas queda cerca del umbral (0.095250). Estos cambios pueden afectar las predicciones y el calendario operativo, pero no demuestran la causa de los errores ni equivalen a concept drift.

## Integridad y alcance

En referencia y septiembre se comprobaron **cero valores faltantes, cero claves estación-hora duplicadas y cero columnas constantes**. El reporte de calidad cuenta diez columnas porque incluye el timestamp junto con las nueve monitorizadas. La reproducción independiente de los cuatro reportes P1/P2 coincide con los resultados del equipo con tolerancia 1e-12; se conserva la evidencia original y su comprobación en Git.

En P2, station_id también cambia (0.260465 en septiembre), pero su champion de persistencia solo usa ocupación virtual: el cambio de estación es contexto y no una entrada directa de esa regla. La ocupación no supera el umbral (0.074505). La comparación A/B de esta entrega se concentra en P1, suficiente para el alcance solicitado.

## Implicación medida para P1

La comparación por segmentos de la página siguiente muestra que B mejora el MAE en estaciones conocidas y nuevas. Sin embargo, el WAPE de las nuevas sigue por encima de 100 %. Su MAE menor se explica en parte por su bajo volumen y no permite concluir que estén bien atendidas. El WAPE mide error absoluto total dividido entre demanda total; no es porcentaje de predicciones incorrectas.

# 3. A/B de dos versiones del Registry

Se reprodujo el entrenamiento existente desde un clon limpio de **61f237f** en un Registry local aislado. Ambas versiones pertenecen a **mibici-p1-demanda**: A = v1 (@champion), enero-junio; B = v2 (@challenger), enero-agosto. Son HGB con estación, pérdida Poisson, semilla 42 y los mismos hiperparámetros: learning_rate=0.1, max_iter=100, max_leaf_nodes=31 y l2=0. El agrupador conserva 254 estaciones y agrupa las restantes como “otras”.

Se cargaron por URI numérica y firma, comprobando linaje y versiones de datos. A y B predijeron las **mismas 338,690 filas** de septiembre. El comparador 17eb729 se ejecutó con árbol limpio y registró parámetros, métricas, hashes y artefactos en MLflow; los IDs completos están en el anexo (MLflow, s. f.).

| Métrica actual | A: versión 1 | B: versión 2 |
|---|---|---|
| MAE (viajes / hora) | 0.862040 | 0.857719 |
| RMSE (viajes / hora) | 1.668304 | 1.611107 |
| WAPE | 59.7064 % | 59.4071 % |
| $R^2$ | 0.642540 | 0.666630 |

| Segmento respecto de A | Filas | MAE A | MAE B |
|---|---|---|---|
| 413 estaciones conocidas | 297,360 | 0.916137 | 0.911665 |
| 58 estaciones nuevas | 41,330 | 0.472829 | 0.469591 |

La reducción relativa del MAE es **0.5013 %**. La diferencia pareada MAE(A)-MAE(B) es **0.004321**; su IC95 % es **[0.002236, 0.006238]**. Se usaron 5,000 réplicas con bloques circulares de siete días y semilla 42, remuestreando juntos los errores de todas las estaciones de cada día. Así no se tratan las filas como independientes (Sheppard, s. f.).

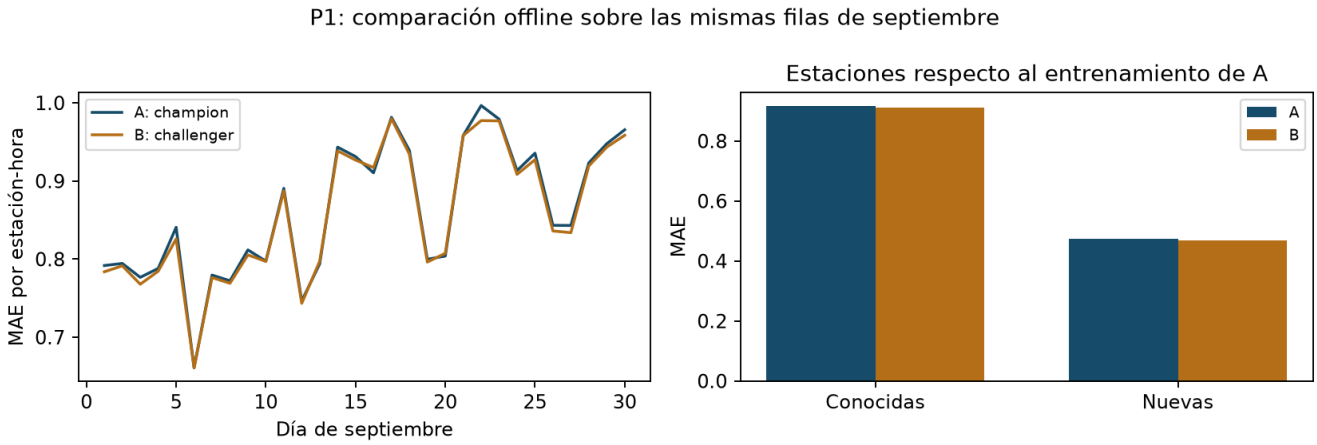



**Figura 2.** MAE diario y por segmento calculado con los modelos registrados. B mejora globalmente, aunque no gana todos los días. Fuente: resultados.json y comparacion.png.

**Límite:** A/B offline retrospectivo; no hay asignación aleatoria de tráfico. Septiembre ya se había consultado en entregas previas. No se reajustaron hiperparámetros con esta comparación; el intervalo, con solo 30 días, no prueba una ventaja en meses futuros.

# 4. Decisión y Continuous Training

**Se recomienda la versión B como vigente.** Cumple las cuatro reglas del protocolo: menor MAE, IC95 % de la mejora por encima de cero, RMSE sin aumento y MAE en estaciones nuevas sin aumento. La ganancia es pequeña: 0.004321 viajes por estación-hora. No se afirma un ahorro operativo porque no se dispone de un costo de errores. La comparación conserva los alias y registra la recomendación; no ejecuta una promoción automática.

## Política de mantenimiento del modelo

**1. Monitorear mensualmente.** Revisar integridad, cobertura de estaciones y distancias por variable. Cuando existan etiquetas, medir MAE, RMSE y WAPE globales y por estaciones conocidas/nuevas. Revisar específicamente el WAPE de B en estaciones nuevas: **101.23 %**.

**2. Investigar antes de reentrenar.** Una alerta abre revisión del catálogo, volumen, estacionalidad y calidad. No se reentrena solo porque cambie una distribución. Se justifica una alternativa si cambian las condiciones y hay degradación relevante o nueva cobertura que incorporar.

**3. Entrenar y comparar.** Usar exclusivamente datos anteriores a una ventana futura con etiquetas; registrar otra versión y comparar ambos modelos sobre las mismas filas con las cuatro reglas anteriores. Conservar los hiperparámetros y el periodo de evaluación documentados para evitar selección oportunista.

**4. Cambiar con trazabilidad.** Registrar la decisión, revisar compatibilidad de la firma con la API y promover la versión aprobada; conservar la anterior para reversión. Repetir el monitoreo tras el cambio. Los umbrales de costo operativo se definen con el operador, sin inventarlos en esta actividad.

## Verificación y colaboración de esta entrega

La revisión aprobó **259 pruebas y 16 subpruebas**, Flake8 y MkDocs estricto. Bandit no detectó hallazgos medios/altos; el escaneo del repositorio e historial no encontró secretos. La auditoría de dependencias pasó con las excepciones previamente documentadas por el equipo. La reproducción y los hashes se conservan en reports/abtest/.

| Integrante | Aportación comprobable |
|---|---|
| Efren Pazzi Manzano | Evidently, pruebas, HTML y capturas. PR #20. |
| Aldo Isai Pérez Hernández | Interpretación del drift e implicaciones. PR #21. |
| Franco Francisco Peña Colorado | Periodos, métricas y nueva versión registrada. PR #22 y PR #23. |
| Leonardo Peraza Alavez | A/B, pruebas, reproducción independiente y reporte. Commit 17eb729. |

**Conclusión.** El drift se concentra en la distribución de estaciones. Reentrenar con historia reciente produce una mejora pequeña y reproducida; B es la opción recomendada para el periodo estudiado. La decisión se sostiene con métricas pareadas y vigilancia por segmento, no con la alerta global por sí sola.

# Anexo A. Evidencia visual original

**Dataset Summary**

| Metric | Current | Reference |
|---|---|---|
| id column | None | None |
| target column | None | None |
| prediction column | None | None |
| date column | None | None |
| number of columns | 10 | 10 |
| number of rows | 338690 | 1552105 |
| missing values | 0 | 0 |
| categorical columns | 4 | 4 |
| numeric columns | 5 | 5 |
| text columns | 0 | 0 |
| datetime columns | 1 | 1 |
| empty columns | 0 | 0 |
| constant columns | 0 | 0 |
| almost constant features | 0 | 0 |
| duplicated columns | 0 | 0 |
| almost duplicated features | 0 | 0 |

**Figura A1.** Resumen de calidad de Evidently: referencia 1,552,105 filas, actual 338,690; sin faltantes ni columnas vacías/constantes. La comprobación de claves duplicadas está también en resumen.json. Captura conservada del equipo.

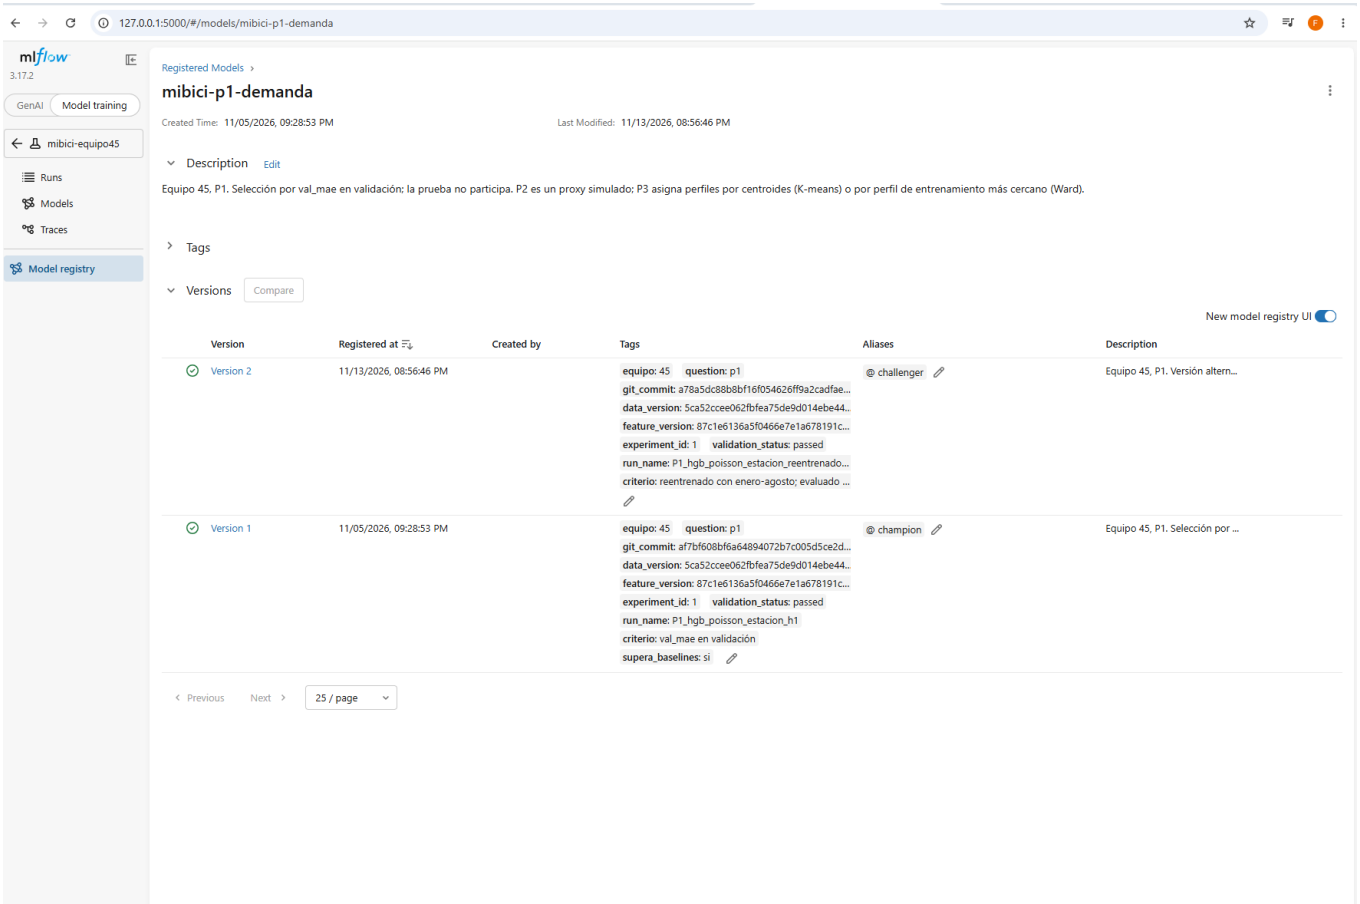



**Figura A2.** Captura original de Franco: versiones 1 y 2 de mibici-p1-demanda, alias champion y challenger. Corresponde a su Registry local y a sus runs. La reproducción independiente tiene otros IDs, detallados en el anexo B; no se confunden ambas ejecuciones.

Las gráficas de distribuciones originales pueden ampliarse en el HTML de Evidently de P1. También se conserva el HTML de P2. La imagen de la figura 1 procede de esos reportes; no es una recreación de su interfaz.

# Anexo B. Reproducción y referencias

## Trazabilidad de la comparación

Entrenamiento A: a9284a97452a4a2383b1ca148d9a15c7
Entrenamiento B: ad655fdb19c042a190b794e084684c8c
Comparación: 7a429366dfcd415e80e0a167217deebe
Código de entrenamiento: 61f237f05e5ddddd8101460a6b8e7524f8cf8c21
Código A/B: 17eb7296b0c04ba7ad62e363b46d82506d2fdb02

SHA-256 de las filas de evaluación:
7728e0f935f0a27ca4405da1836e59694c5ee9655bf250af847352d3ee7bd757
Los manifiestos verifican los CSV y Parquet; no se publican datos por viaje, bases de MLflow ni modelos serializados en Git.
Versiones: MLflow 3.17.2, scikit-learn 1.9.1, Evidently 0.7.23, Python 3.13.15.

## Ejecución desde la raíz del repositorio

Instalar requirements-validation.txt; generar y verificar ingesta y variables según el README. Configurar MLFLOW_TRACKING_URI para un servidor o Registry local. Cada línea siguiente corresponde a un comando; el detalle por sistema operativo está en el repositorio.

```
python -m mibici.monitoring --current sep jul_ago
```

```
python -m mlflow run . -e train --env-manager local --experiment-name mibici-equipo45 -P question=p1 -P model=hgb_station -P register=true -P train_window=train
```

```
python -m mlflow run . -e train --env-manager local --experiment-name mibici-equipo45 -P question=p1 -P model=hgb_station -P register=true -P train_window=train_val
```

```
python -m mibici.abtest --champion-version 1 --challenger-version 2
```

```
python -m pytest -q
```

Las versiones numéricas dependen del historial del Registry. En uno nuevo se generaron 1 y 2; también se aceptan los alias. Código, resultados completos y protocolo en GitHub.

## Referencias

Evidently AI. (s. f.). *What is Evidently?* Recuperado el 14 de noviembre de 2026, de https://docs.evidentlyai.com/introduction

MLflow. (s. f.). *Model Registry workflows.* Recuperado el 14 de noviembre de 2026, de https://mlflow.org/docs/latest/ml/model-registry/workflow/

Sheppard, K. (s. f.). *Time-series bootstraps.* arch. https://arch.readthedocs.io/en/latest/bootstrap/timeseries-bootstraps.html

Equipo 45. (2026). *MiBici: monitoreo de drift y comparación de versiones* [Repositorio de código]. GitHub. https://github.com/A01793289-Franco/mna-mibici-equipo45