

Tecnológico de Monterrey

Proyecto MiBici
Propuesta y base reproducible

Operaciones de aprendizaje automático (MLOps)
TC5061

Equipo 45

Efren Pazzi Manzano
Franco Francisco Peña Colorado
Leonardo Peraza Alavez
Aldo Isai Pérez Hernández

Profesor: Iván Reyes Amezcua

18 de octubre de 2026

Repositorio y rama de esta entrega

Propuesta, ingesta, variables, exploración y seis corridas reales registradas en MLflow.

1. Formulación del problema

El proyecto busca apoyar tres decisiones del sistema de bicicleta pública MiBici, en el Área Metropolitana de Guadalajara. La unidad operativa es la estación; la información de viajes permite estudiar demanda y patrones, pero no contiene inventarios reales. El ML Canvas se incluye como anexo, conservando la plantilla original (Dorard, 2016).

Pregunta	Qué se estima	Usuario y utilidad
P1: regresión	Viajes iniciados por estación durante la siguiente hora.	Operador: anticipar demanda y planear la distribución de la flota.
P2: clasificación	Estado virtual al cierre de la siguiente hora: normal, riesgo sin bicicletas o sin anclajes.	Rebalanceo: priorizar estaciones para revisión; requiere validar el proxy.
P3: clustering	Tres grupos por perfil horario normalizado de uso, ubicados en un mapa.	Planeación: comparar patrones y estudiar cobertura o expansión.

Para P1 y P2 se predice al inicio de la hora local t usando eventos anteriores a t. El horizonte es [t, t + 1 hora). P3 es un análisis por lotes; se propone una actualización mensual. Las coordenadas se usan para ubicar grupos, no para imponer cercanía geográfica al agrupar.

Cómo se aproxima el riesgo de P2

Se inicia cada estación con 50% de su capacidad. Cada salida resta una bicicleta virtual y cada llegada la suma cuando el viaje termina. Se agregan eventos simultáneos y se recorta el estado entre cero y la capacidad. En el cierre de la siguiente hora se etiqueta riesgo sin bicicletas si la ocupación es de 10% o menos, y riesgo sin anclajes si es de 90% o más; el resto es normal.

Es una hipótesis reproducible, no una medición del inventario. Omite rebalanceos, averías y cambios históricos de capacidad. Solo mide el cierre de hora, por lo que puede omitir incidentes transitorios. No se propone automatizar decisiones de rebalanceo con estos resultados. El escenario evaluado utiliza una ocupación inicial de 50%.

2. Datos, calidad y condiciones de uso

Se utilizaron nueve meses completos, enero-septiembre de 2026, y el catálogo de estaciones de septiembre. Este periodo permite observar ciclos semanales y cambios mensuales; no cubre un ciclo anual. La fuente es el portal oficial de MiBici (s. f.-b). Cada mes siguiente es un enlace al archivo descargado.

Mes / enlace CSV	Originales	Válidos	Inválidos	Duplicados
2026-01	357,180	356,918	262	0
2026-02	333,756	331,893	1863	0
2026-03	376,243	376,028	215	0
2026-04	351,851	351,689	162	0
2026-05	315,895	315,819	76	0
2026-06	355,303	355,187	116	0
2026-07	388,257	388,175	82	0
2026-08	393,524	393,437	87	0
2026-09	490,056	489,127	171	758
Total	3,362,065	3,358,273	3,034	758

Se observaron **471 IDs de estación**. El catálogo contiene 480 estaciones válidas de 484 filas; los IDs 405 y 407 observados en viajes no aparecen en él. Descargar catálogo de septiembre.

Variables y limpieza

Se utilizan ID del viaje para deduplicar, inicio, fin, estación de origen y destino; del catálogo: ID, nombre, capacidad, latitud y longitud. El esquema limpio tiene enteros para identificadores y fechas con zona America/Mexico_City. Se normalizan nombres, codificación y fechas; se descartan filas inválidas y duplicados. La ingesta guarda Parquet mensual y un manifiesto con URL, SHA-256 y conteos.

Los identificadores de usuario, género y año de nacimiento se excluyen antes del almacenamiento limpio. Los artefactos muestran agregados por estación y hora. No se publica ningún archivo por viaje en Git. El notebook examina distribuciones; recortar una figura al percentil 99 facilita verla y no elimina valores del conjunto.

El portal permite descargar los CSV; al revisar sus páginas de datos, términos y privacidad no se identificó una licencia específica de redistribución. No se atribuye a los datos la licencia MIT del código. Las condiciones del servicio no equivalen a una licencia de datos (MiBici, s. f.-a, s. f.-b, s. f.-c).

3. Partición y prevención de fuga temporal

Conjunto	Periodo	Uso
Entrenamiento	Enero-junio 2026	Ajustar transformaciones y modelos.
Validación	Julio-agosto 2026	Comparar configuraciones fijadas previamente.
Prueba	Septiembre 2026	Evaluación final única de P1 y P2.

Los intervalos incluyen su inicio y excluyen su fin. Se eliminan horizontes que cruzan un corte y el inicio con historia insuficiente. No se dividen filas al azar. Los rezagos y medias excluyen la hora objetivo. Escalado y pesos de clase se aprenden solo con entrenamiento; las tablas comprobadas no tienen predictores faltantes.

La evaluación representa pronósticos consecutivos a una hora: puede utilizar observaciones previas ya conocidas de validación o prueba, sin reentrenar. No representa predecir un mes entero desde una fecha única. Una llegada solo está disponible después del fin del viaje.

Tabla modelable	Entrenamiento	Validación	Prueba
P1: estación-hora	1,552,105	665,747	338,690
P2: estación-hora	1,551,437	662,771	337,250
P3: perfiles por estación	397	468	468*

*Los perfiles de septiembre se generan, pero la versión actual no calcula métricas de prueba de P3. Su comparación temporal utiliza entrenamiento y validación, con 397 estaciones comunes.

Límites de los metadatos y de la cobertura

El catálogo de septiembre es un metadato fijo para este ejercicio retrospectivo. No prueba fechas de alta ni capacidad histórica. La capacidad se excluye de los predictores de P1; P2 requiere metadatos históricos para validación operativa. Las horas cero se completan dentro de periodos de cobertura y actividad observada; no demuestran que la estación estuviera operativa sin interrupciones.

Versiones y trazabilidad

Los seis runs se ejecutaron con semilla 42 desde el commit **43bf339792fef5d01326aa0ca0227fdd781675ff**, con **git_dirty=false**. El protocolo y las configuraciones estaban confirmados antes de consultar los resultados de septiembre.

Datos SHA-256: 4bd1e3ecd2beb758f102660a4dcc7e11e726f25245e2da51cec43be6f22b560f

Variables SHA-256: b588c6194acd2227f1ff9de4c097d536b8465d30dc9633b4a3284019ec60e09b

4. Pipelines, modelos y métricas

P1. Demanda por estación

Flujo: normalizar viajes → validar calidad → contar salidas por estación-hora → calendario y rezagos 1/24/168 h, medias previas de 24/168 h → cortes temporales → ajuste y evaluación. Estas variables representan persistencia y ciclos; no usan la hora por predecir.

Baseline: misma estación y hora de la semana anterior; sin historia, promedio por estación/hora semanal y respaldo global aprendido en entrenamiento. **Candidato:** HistGradientBoostingRegressor, pérdida Poisson, learning_rate=0.1, max_iter=100, max_leaf_nodes=31, semilla 42. La pérdida es apropiada para conteos no negativos.

Métricas: MAE principal, RMSE para errores grandes, WAPE global y R^2 complementario. WAPE es suma de errores absolutos dividida entre suma de demanda. MAPE no se usa por las horas con cero; si el total es cero, WAPE queda no definido (Scikit-learn developers, s. f.).

P2. Riesgo virtual

Flujo: viajes → eventos de salida/llegada finalizada → ocupación virtual causal → etiqueta futura → calendario, ocupación previa y flujo histórico → partición → ajuste y clasificación. Se excluye el flujo y estado de la hora objetivo. No se incorporan predicciones de P1 en esta versión.

Baseline: StandardScaler y LogisticRegression balanceada, max_iter=1000. **Candidato:** HistGradientBoostingClassifier balanceado, learning_rate=0.1, max_iter=100, max_leaf_nodes=31. Los pesos dependen de entrenamiento. **Métricas:** F1 macro, balanced accuracy, precisión/recall por clase y average precision macro uno contra el resto. AP no se confunde con área trapezoidal PR.

P3. Patrones de uso

Flujo: salidas → medias de cada hora en días laborales y fines de semana → perfil de 48 componentes → normalización L1 → agrupación y mapa. Se exige cobertura de al menos 14 días completos y se excluyen perfiles nulos. Normalizar evita que el volumen domine la forma del patrón.

Baseline: KMeans(k=3, n_init=10, random_state=42). **Candidato:** agrupamiento jerárquico Ward(k=3). Tres grupos es una decisión inicial, no un resultado descubierto. **Métricas:** silhouette mayor, Davies-Bouldin menor, tamaños e interpretabilidad; ARI entre agrupaciones de entrenamiento y validación en estaciones comunes. Las coordenadas son solo para el mapa.

5. Arquitectura y herramientas

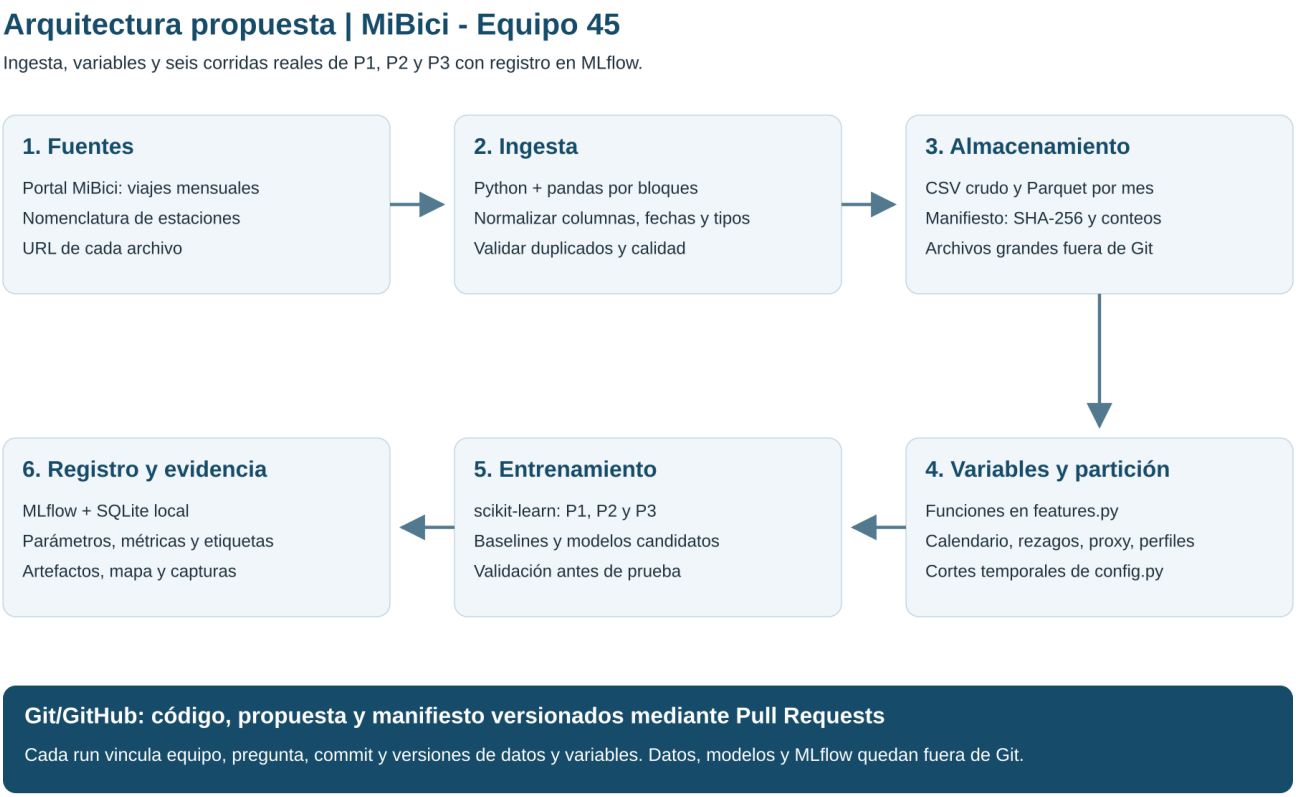


Figura 1. Arquitectura del proyecto: ingesta, procesamiento, entrenamiento y registro. Fuente: elaboración del equipo.

Herramienta	Función y justificación
Python y pandas	Ingesta por bloques y normalización. La calidad y disponibilidad de datos forman parte del diseño del sistema (Huyen, 2022).
Parquet y PyArrow	Almacenamiento mensual eficiente; conserva el origen local y permite lecturas por columnas.
SHA-256 y Git	Manifiestos ligan archivos, código y versiones sin agregar datos al repositorio (Treveil et al., 2020).
Cookiecutter Data Science	Separa módulo, datos, exploración, modelos y reportes; config.py centraliza fechas, rutas y semilla (DrivenData, s. f.).
scikit-learn y Matplotlib	Modelos sencillos, métricas por tarea y gráficos para interpretar errores y grupos.
MLflow y SQLite local	Registra parámetros, métricas, commit y artefactos. El servidor es local; otros integrantes reproducen sus runs (MLflow, s. f.).

6. Resultados de P1: demanda

Se compararon dos configuraciones fijadas antes de la prueba. El candidato mejora frente al baseline tanto en validación como en septiembre. Las tablas usan cuatro decimales; el JSON conserva toda la precisión.

Conjunto / modelo	MAE	RMSE	WAPE	R^2
Validación / Estacional	0.8988	1.8185	0.7676	0.4067
Validación / Boosting	0.7614	1.4363	0.6503	0.6299
Prueba / Estacional	1.0264	2.1075	0.7109	0.4296
Prueba / Boosting	0.8719	1.6345	0.6039	0.6569

En septiembre, el MAE pasa de 1.0264 a **0.8719 viajes por estación-hora**, una reducción aproximada de 15.1%. El RMSE pasa de 2.1075 a 1.6345: también se reducen errores grandes. R^2=0.6569 mejora respecto al baseline, sin garantizar el mismo comportamiento en todas las estaciones.

El WAPE de 0.6039 equivale a **60.39% de error absoluto respecto al volumen total observado**. No es exactitud ni significa que 60.39% de las predicciones sean incorrectas. Sigue siendo un error importante para uso operativo; conviene desagregar por estación, horario y nivel de demanda.

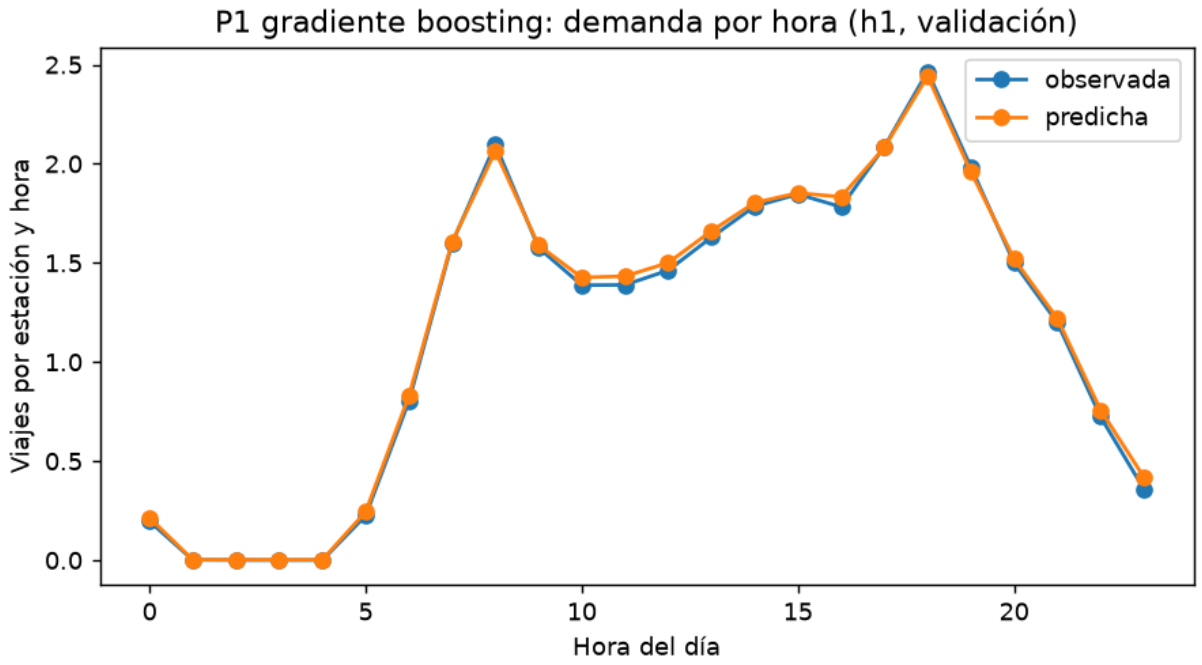


Figura 2. Artefacto de P1: medias por hora en validación. Una coincidencia en el promedio no asegura precisión en cada estación. Fuente: run P1_hgb_poisson_h1.

La comparación no aísla un hiperparámetro: cambian la familia y el mecanismo del modelo. No se realizó búsqueda de hiperparámetros ni se ajustaron decisiones después de ver septiembre.

7. Resultados de P2: riesgo simulado

Conjunto / modelo	F1 macro	Balanced acc.	AP macro
Validación / Logística	0.8223	0.8856	0.9034
Validación / Boosting	0.8708	0.9085	0.9557
Prueba / Logística	0.8114	0.8799	0.8848
Prueba / Boosting	0.8574	0.9006	0.9463

El F1 macro mejora de 0.8223 a 0.8708 en validación y de 0.8114 a **0.8574 en prueba**. La mejora se mantiene en un periodo posterior. En septiembre, el candidato alcanza recall de 0.9363 para riesgo sin anclajes, pero precisión de 0.6987: parte de las alertas son falsas.

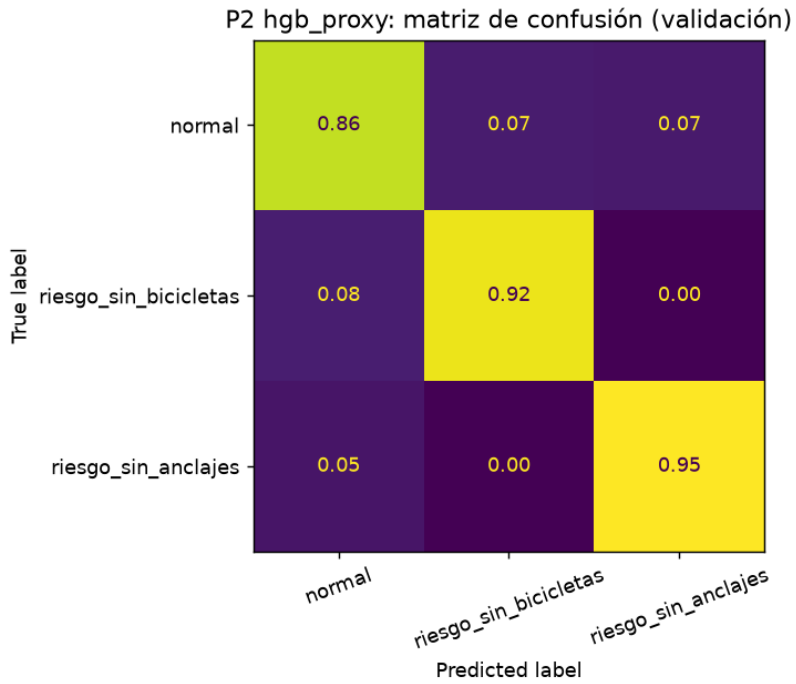


Figura 3. Matriz de confusión de validación. Fuente: run P2_hgb_proxy_h1.

Alcance: el objetivo es generado por la misma simulación cuyo estado anterior se usa como predictor. La persistencia de ese estado facilita la clasificación. El resultado demuestra concordancia con un proxy, no inventario real ni seguridad de una intervención automática.

El escenario acumuló 447,278 eventos recortados en los límites de capacidad y excluyó 5,084 filas sin capacidad o historia suficiente. Es una limitación del estado virtual: los resultados se interpretan exclusivamente dentro del escenario simulado, sin demostrar disponibilidad física.

8. Resultados de P3: grupos de estaciones

Modelo	Silhouette ↑	Davies-Bouldin ↓	ARI validación ↑
K-means	0.1407	1.9784	0.5776
Ward	0.1232	2.1388	0.3116

K-means resulta preferible en las tres métricas. Sus grupos contienen 213, 33 y 151 estaciones, frente a 217, 149 y 31 en Ward. Se ajustaron perfiles de 397 estaciones de entrenamiento; validación tiene 468 y la estabilidad se calcula en las 397 comunes.

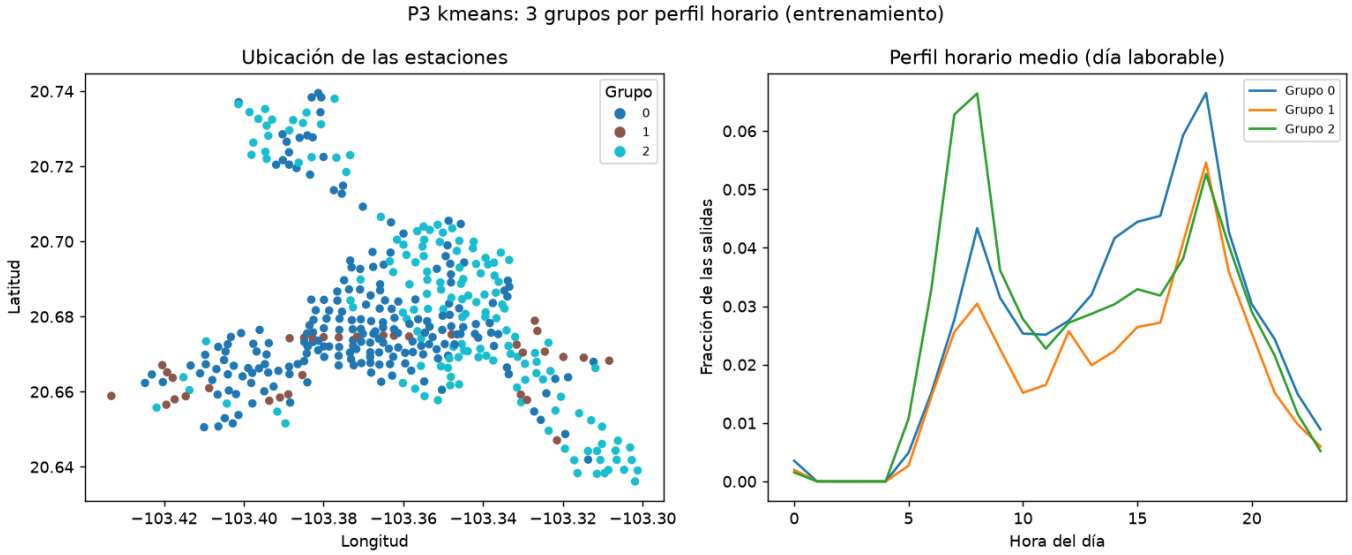


Figura 4. Ubicación de los grupos y su perfil laboral medio; coordenadas públicas de estaciones. Fuente: run P3_kmeans_perfil48.

El grupo 2 concentra mayor actividad relativa en la mañana; el 0 tiene una distribución más extendida en la tarde. El mapa muestra que los comportamientos se mezclan espacialmente. Estas son descripciones de perfiles agregados, no categorías sociales de quienes usan las bicicletas.

Silhouette=0.1407 indica **separación baja**: no hay evidencia de tres tipos naturales claramente distintos. ARI=0.5776 refleja estabilidad parcial entre periodos, no coincidencia perfecta. Ward es menos estable. No se calcularon métricas de P3 sobre septiembre.

La interpretación combina métricas internas, estabilidad temporal y el mapa de estaciones. Con esta evidencia, K-means es la alternativa más consistente de las dos configuraciones evaluadas.

9. Evidencia de MLflow: lista de runs

Experimento **mibici-equipo45**. Se registraron baseline y candidato para cada pregunta, con nombres descriptivos. Todos los runs terminaron. Las capturas siguientes son de la interfaz real del registro local.

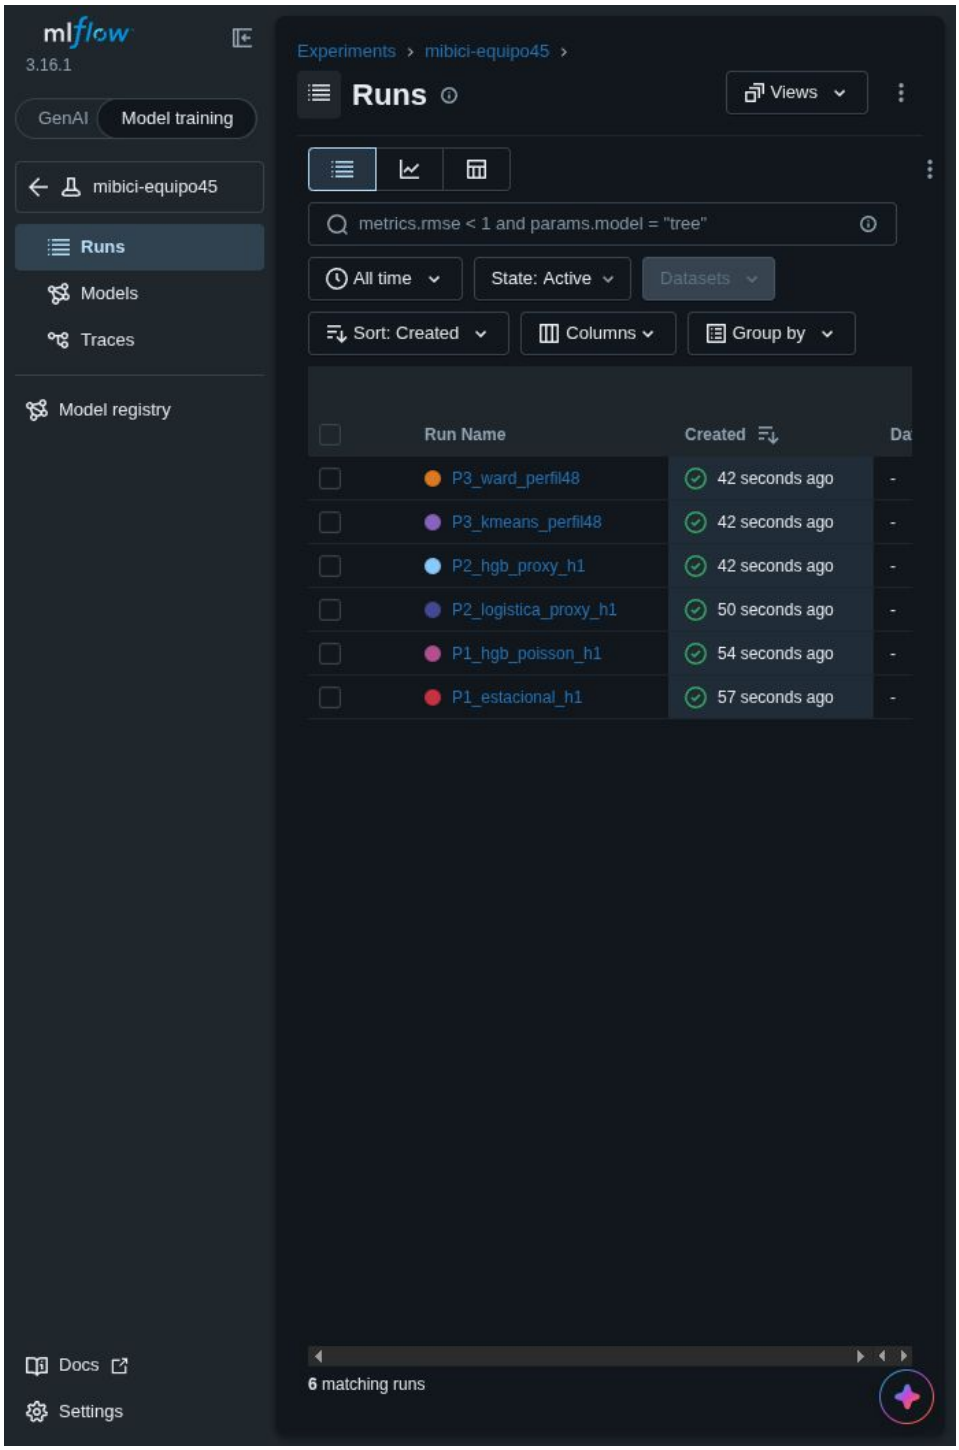


Figura 5. Seis corridas en el mismo experimento: dos para P1, dos para P2 y dos para P3. La base local y la carpeta de artefactos se excluyen de Git; las capturas permiten revisar la ejecución sin publicarlas.

10. Detalle de un run: etiquetas y commit

Run **P1_hgb_poisson_h1**. Esta primera vista muestra estado, commit y etiquetas. La siguiente continúa con métricas y parámetros.

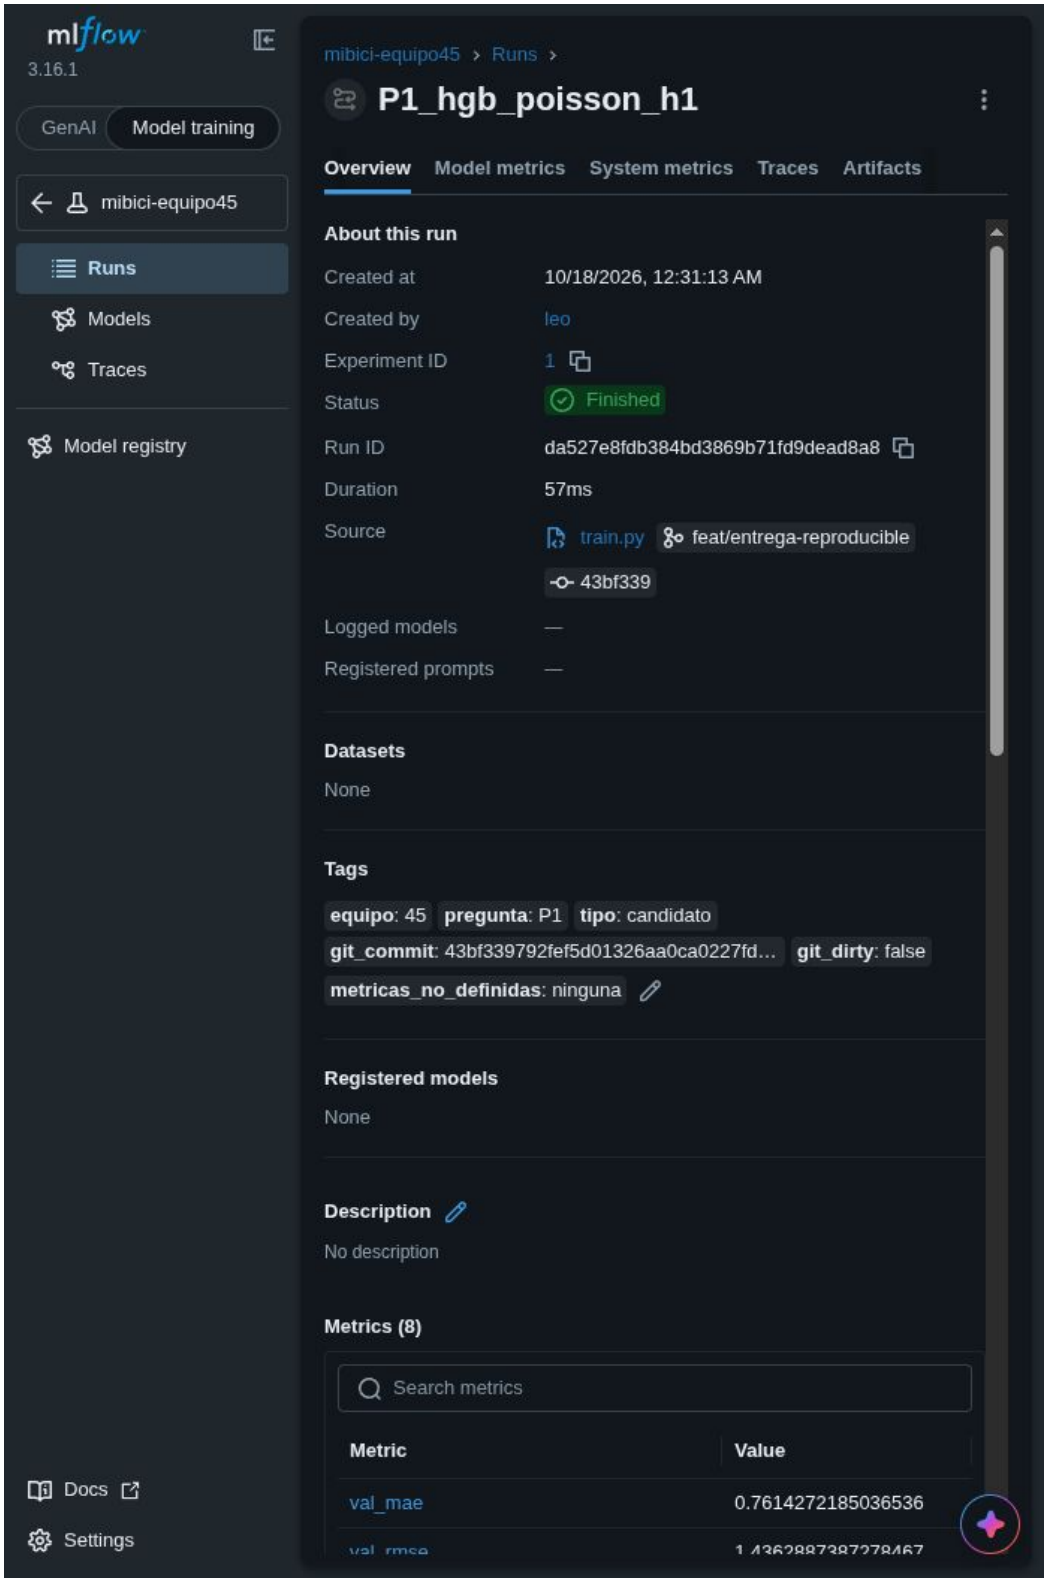


Figura 6a. Run finalizado, equipo 45, pregunta P1, tipo candidato, commit 43bf339 y git_dirty=false. El tiempo mostrado corresponde al bloque de registro; no se usa como medición del entrenamiento.

11. Detalle de un run: métricas y parámetros

La interfaz registra métricas de validación y prueba, semilla, cortes temporales, horizonte y versiones de datos/variables. Los hiperparámetros completos se conservan en el registro y en el JSON de resultados.

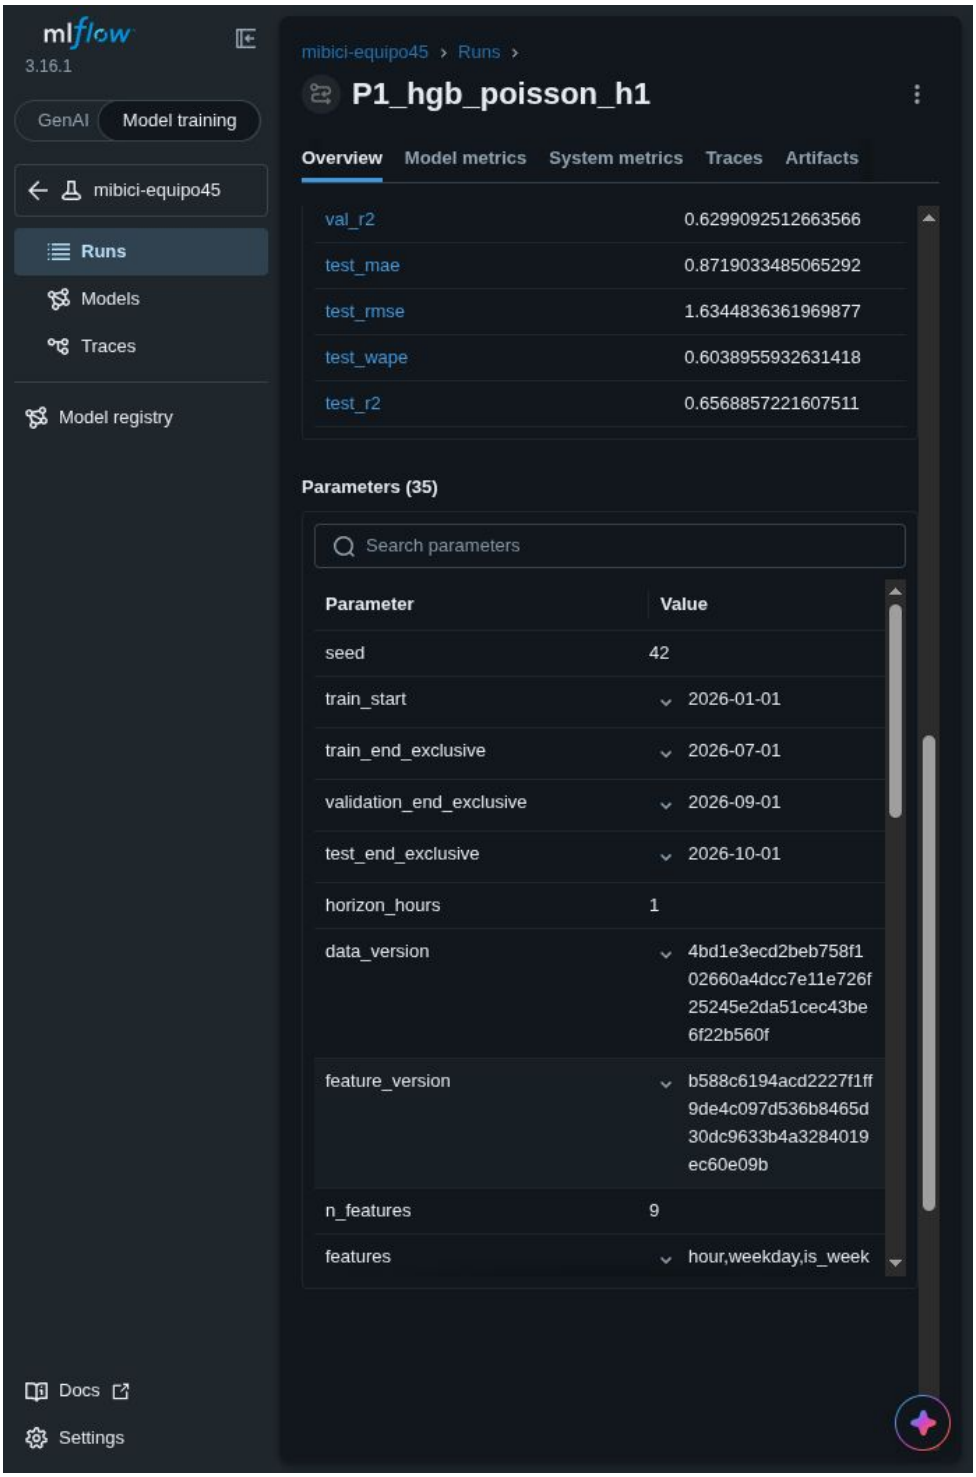


Figura 6b. Continuación del mismo run. Se observan test_mae, test_rmse, test_wape y test_r2 junto con parámetros de reproducción.

12. Evidencia de un artefacto registrado

El run conserva una figura de demanda en la carpeta **figuras**. P2 registra una matriz de confusión; P3, mapa/perfiles y tabla de grupos. La actividad exige al menos un artefacto por pregunta.

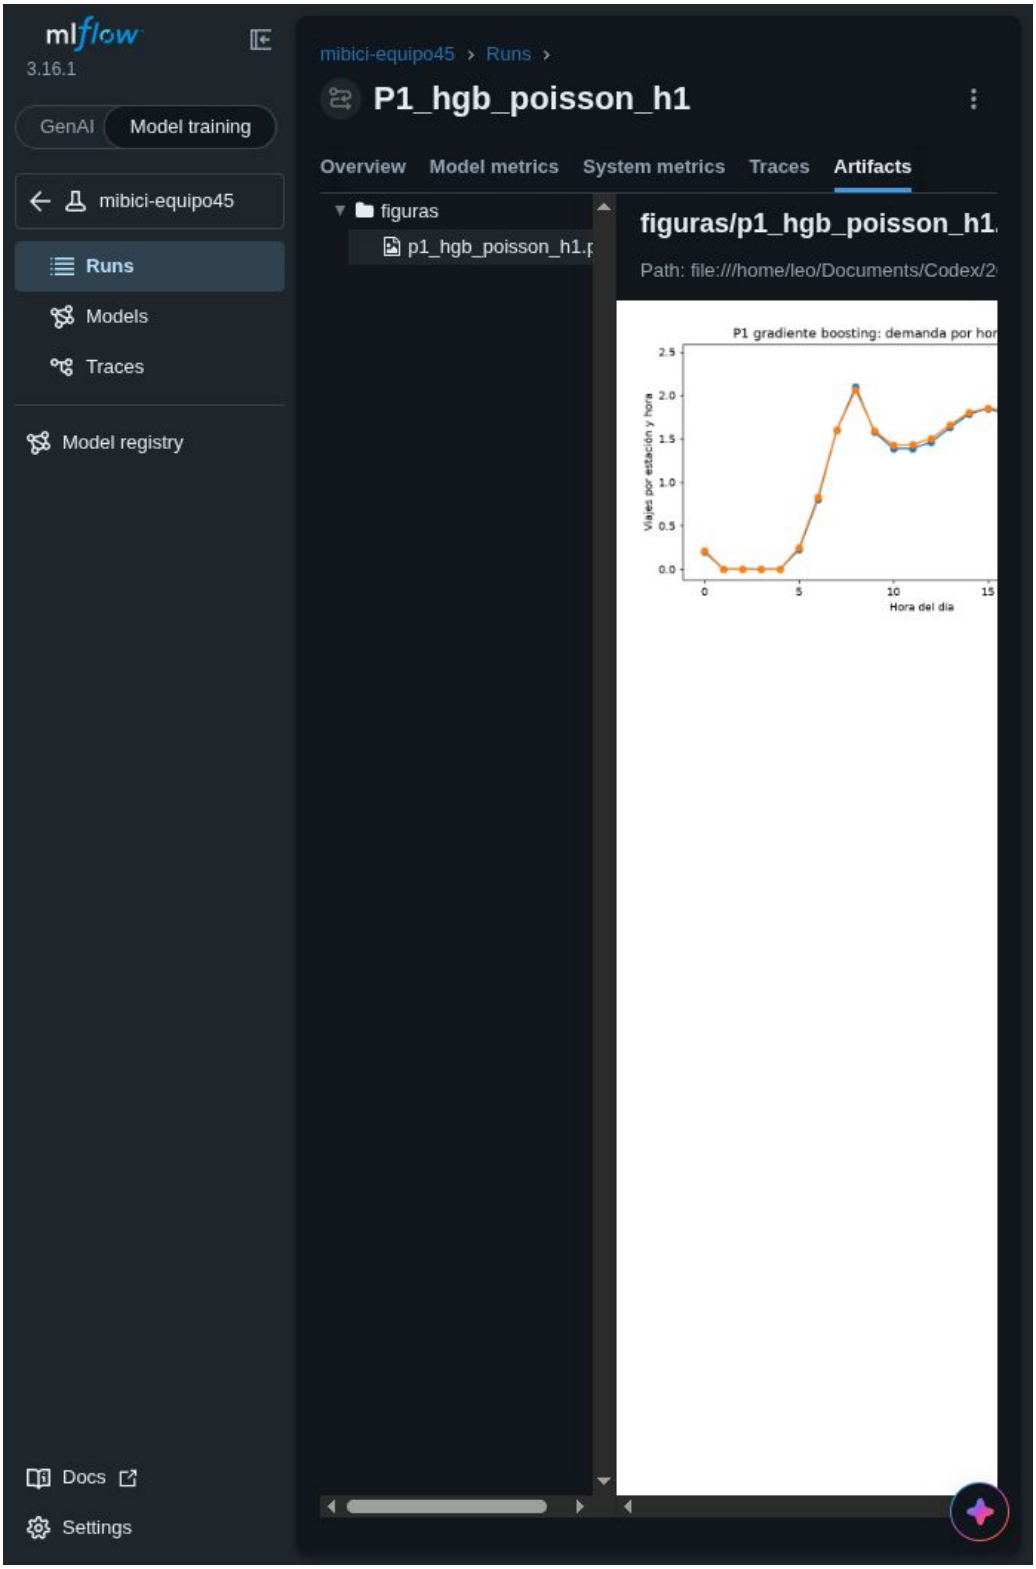


Figura 7. Artefacto real figuras/p1_hgb_poisson_h1.png en la pestaña Artifacts. El documento no incluye modelos serializados ni los datos de viajes.

13. Comparación desde la interfaz

Comparación entre **P1_hgb_poisson_h1** y **P1_estacional_h1**, sobre las mismas versiones de datos y los mismos periodos. Las métricas de tareas diferentes no se comparan entre sí.

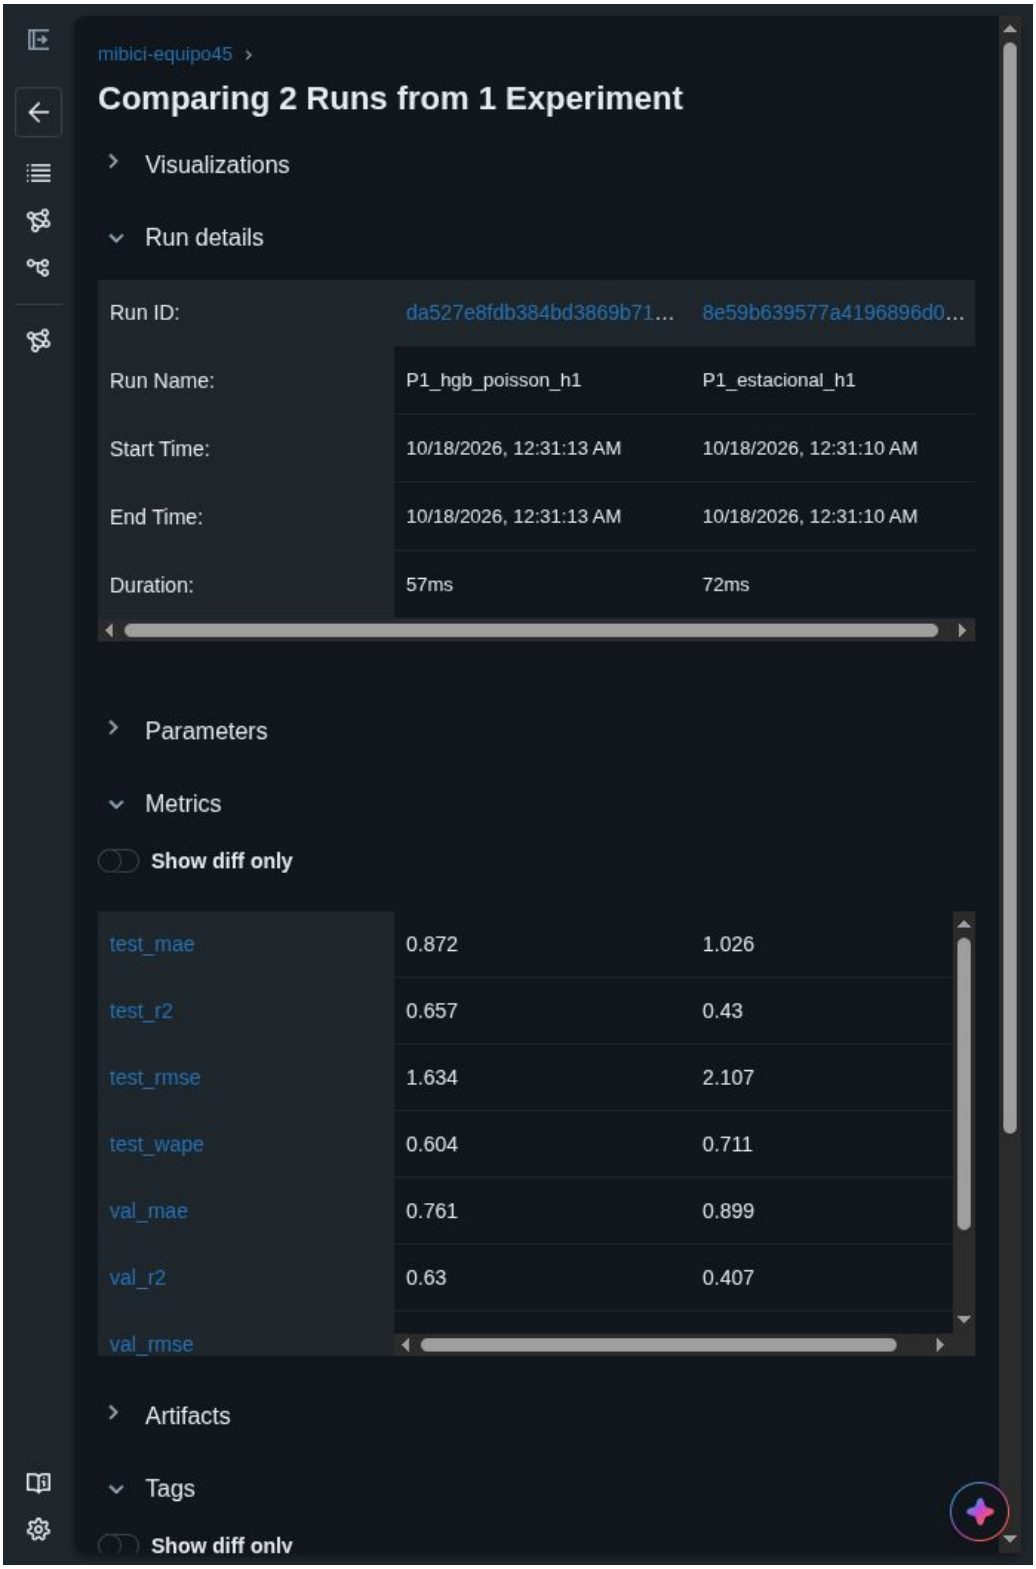


Figura 8. Menor MAE y RMSE en el candidato, tanto en validación como en prueba. MLflow redondea la vista; el registro JSON conserva los valores completos.

14. Repositorio, reproducción y colaboración

Repositorio público: A01793289-Franco/mna-mibici-equipo45. Rama de esta entrega: feat/entrega-reproducible.

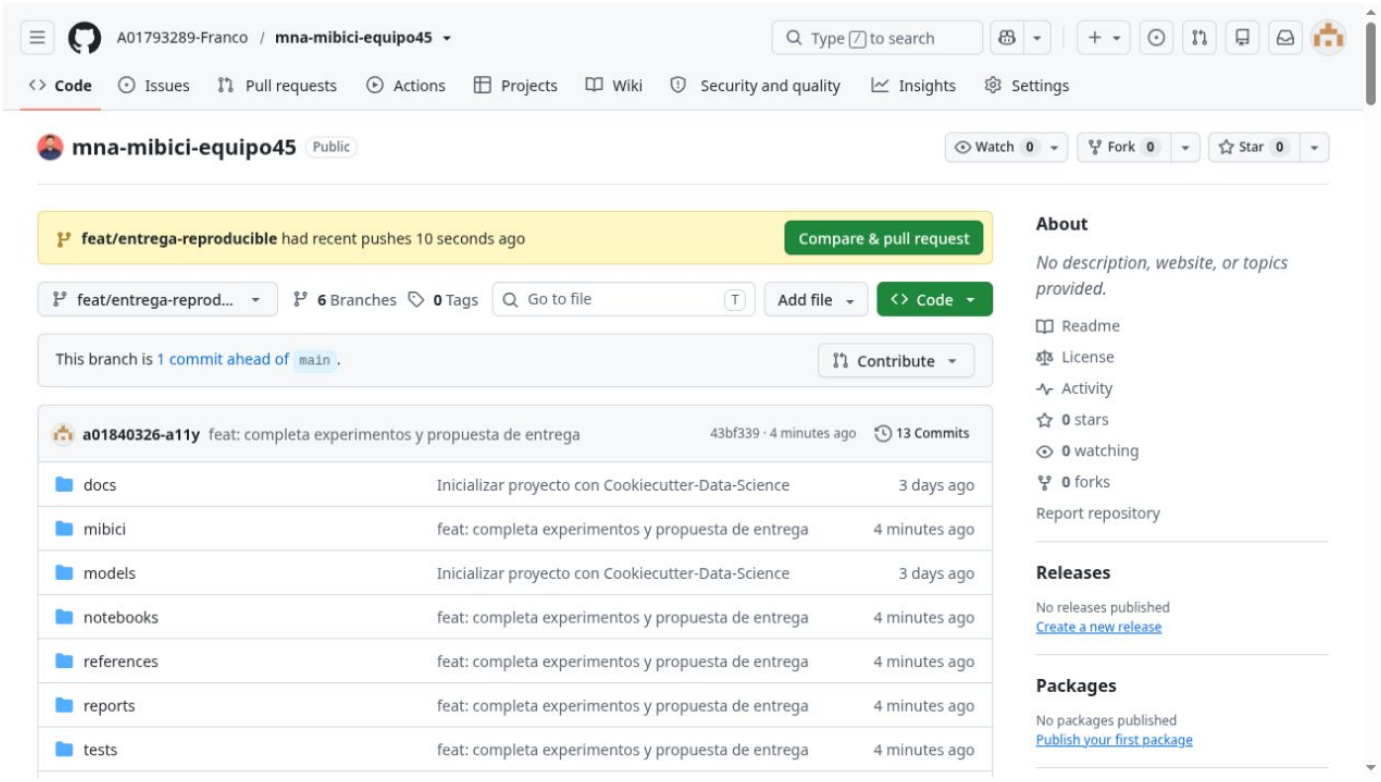


Figura 9. Estructura real en GitHub. data/ se crea localmente mediante config.py; no se versiona. Notebook ejecutado en notebooks/; código final en mibici/.

Desde un entorno Python 3.13, el README indica instalación para Linux/macOS y Windows. Comandos del flujo: **python -m mibici.dataset**, **python -m mibici.features**, **python -m mibici.train --question all** y **python -m mlflow ui --backend-store-uri sqlite:///mlflow.db**. Septiembre solo se evalúa al añadir --final-test después de fijar decisiones. Se verificaron hashes, 21 pruebas y el notebook sin errores; se ejecutó en Linux con Python 3.13.15.

Integrante	Responsabilidad
Franco Francisco Peña Colorado	Estructura, administración y entrenamiento inicial P1.
Efren Pazzi Manzano	Canvas y entrenamiento de las tres preguntas con MLflow.
Leonardo Peraza Alavez	Propuesta, ingesta, variables, versiones, notebook y reporte.
Aldo Isai Pérez Hernández	Revisión e interpretación.

15. Referencias

Dorard, L. (2016, 18 de noviembre). *From data to AI with the Machine Learning Canvas (Part I)*. Own Machine Learning. https://medium.com/louis-dorard/from-data-to-ai-with-the-machine-learning-canvas-part-i-d171b867b047

DrivenData. (s. f.). *Cookiecutter Data Science*. https://cookiecutter-data-science.drivendata.org/

Huyen, C. (2022). *Designing machine learning systems: An iterative process for production-ready applications*. O'Reilly Media.

MiBici. (s. f.-a). *Aviso de privacidad*. Recuperado el 18 de octubre de 2026, de https://www.mibici.net/es/aviso-de-privacidad/

MiBici. (s. f.-b). *Datos abiertos* [Conjunto de datos]. Recuperado el 18 de octubre de 2026, de https://www.mibici.net/es/datos-abiertos/

MiBici. (s. f.-c). *Término y condiciones*. Recuperado el 18 de octubre de 2026, de https://www.mibici.net/es/termino-y-condiciones/

MLflow. (s. f.). *MLflow Tracking* [Documentación]. https://mlflow.org/docs/latest/ml/tracking/

Scikit-learn developers. (s. f.). *Metrics and scoring: Quantifying the quality of predictions*. https://scikit-learn.org/stable/modules/model_evaluation.html

Treveil, M., Omont, N., Stenac, C., Lefevre, K., Phan, D., Zentici, J., Lavoillotte, A., Miyazaki, M., & Heidmann, L. (2020). *Introducing MLOps: How to scale machine learning in the enterprise*. O'Reilly Media.

Anexo: Machine Learning Canvas

La página siguiente integra el Canvas en su distribución original. Su contenido integra el flujo ejecutado y el diseño de monitoreo del proyecto. El PDF y su contenido editable se conservan también en references/.

Los enlaces mensuales de la sección 2 y los manifiestos permiten rastrear los archivos empleados. Las figuras y capturas son evidencia de esta ejecución del equipo; no representan validación de un sistema en producción.

Made with Visual Paradigm
For non-commercial use

Decisión

P1: Cuántas bicicletas disponer por estación y periodo.

P2: Qué estaciones revisar y priorizar para rebalanceo.

P3: Qué estaciones comparten patrones de uso y dónde se ubican.

Tarea de predicción

P1: Viajes iniciados por estación en la siguiente hora (regresión).

P2: Riesgo virtual al cierre de esa hora: normal, sin bicicletas o sin anclajes.

P3: Tres grupos por perfil horario de uso. Coordenadas solo para el mapa.

Propuesta de valor

P1: El operador anticipa demanda para distribuir la flota.

P2: Rebalanceo prioriza estaciones con riesgo virtual. El proxy no representa inventario real.

P3: Planeación interpreta patrones y ubicación para estudiar cobertura.

Fuentes de datos

CSV mensuales de viajes: enero-septiembre de 2026. Catálogo: nomenclatura_2026_09.csv.

Inicio y fin, estaciones e ID del viaje para deduplicar; capacidad y coordenadas del catálogo.

3,358,273 viajes válidos; 471 IDs observados. Sin atributos personales. Licencia específica de los CSV no identificada.

Recolección de datos

Ingesta ejecutada: descarga, normalización de columnas y fechas; revisión de duplicados y registros inválidos.

CSV crudo local y Parquet mensual. Manifiesto en Git con URL, SHA-256 y conteos.

Enero-septiembre 2026: nueve meses verificados.

Predicciones

P1 y P2: cada hora, usando solo eventos anteriores a la predicción.

Proxy P2: iniciar al 50% de capacidad; acumular llegadas finalizadas menos salidas y recortar entre cero y capacidad.

Umbrales: 10% y 90%. Ocupación inicial utilizada: 50%.

P3: análisis por lotes con actualización mensual propuesta.

Seis runs reales en MLflow. P1-P2 evaluados una vez en septiembre.

Evaluación Offline

Entrenar: enero-junio. Validar: julio-agosto. Prueba: septiembre. Excluir horizontes que cruzan cortes.

P1: MAE, RMSE y WAPE.

P2: F1 macro, balanced accuracy, precisión/recall por clase y AP macro.

P3: silhouette, Davies-Bouldin, mapa/tamaños y ARI en validación.

Ingeniería de características

P1: calendario; rezagos 1/24/168 h y medias 24/168 h, sin hora objetivo.

P2: calendario, ocupación virtual y flujo histórico. Sin predicciones de P1.

P3: 48 medias horarias laborable/fin de semana, normalizadas.

Catálogo posterior fijo: limitación retrospectiva documentada.

Construcción de modelos

P1: baseline estacional (semana anterior). Candidato: gradient boosting para conteos.

P2: baseline de regresión logística balanceada. Candidato: gradient boosting.

P3: baseline K-means (k=3, semilla fija). Candidato: jerárquico Ward (k=3).

Rutas, fechas y parámetros centralizados en mibici/config.py.

Detalle de modelos, métricas y supuestos en propuesta.md.

Evaluación en vivo y monitoreo

Comparar predicciones y observaciones por estación. Vigilar deriva, nuevas estaciones, cambios de capacidad y calidad de datos.

Diseño de monitoreo: contrastar disponibilidad e inventarios del operador. MLflow liga pregunta, versiones y commit. P2 evalúa un estado virtual.